


RAG Nedir ve Ne Zaman Çıktı?

- **Tarihçe:** İlk kez 2020 yılında Patrick Lewis ve Facebook AI Research (FAIR) ekibi tarafından yayımlanan bir makale ile literatüre girdi.
- **Temel Mantık:** Önceden eğitilmiş bir dil modelini (LLM), harici ve güncel bir bilgi tabanı ile birleştiren yenilikçi bir yapay zeka mimarisidir.
- **Dinamik Yapı:** Modelin sadece kendi hafızasına güvenmesi yerine, dış kaynaklardan bilgiyi anında "getirip" (retrieval) cevabı "üretmesini" (generation) sağlar.



RAG Mimarisi Nasıl Çalışır?




1. Vektörleştirme

Kurum içi belgeler küçük parçalara ayrılır, matematiksel vektörlere (embedding) dönüştürülüp veri tabanına kaydedilir. **Model yeniden eğitim (training) gerekmez.**



2. Geri Getirme

Kullanıcı bir soru sorduğunda (Query), vektör veri tabanında arama yapılır ve soruyla anlamsal olarak en çok eşleşen belge parçaları saniyeler içinde bulunur.



3. Üretim

Bulunan en alakalı belgeler (context), dil modeline kullanıcı sorusu ile birlikte iletilir. Model, sadece bu bağlama sadık kalarak güvenilir ve doğru cevabı üretir.

Dokümansız ve Dokümanlı Karşılaştırması

Standart LLM

Dokümansız Kullanım Yaklaşımı

-  **Halüsinasyon:** Modelin yanlış bilgi uydurma riski oldukça yüksektir.
-  **Eski Bilgi:** Modelin eğitildiği tarihteki verilerle sınırlıdır, güncel gelişmeleri bilemez.
-  **Kapalı Kutu:** Üretilen bilginin hangi kaynağa dayandığı belli değildir.

RAG Sistemi

Dış Doküman Destekli Kullanım

-  **Doğrulanabilirlik:** Kaynak gösterme (source attribution) özelliği sayesinde üretilen cevaplar teyit edilebilir.
-  **Güncellik:** Şirketin en güncel, özel ve anlık verileriyle dinamik cevaplar üretir.
-  **Güvenilirlik:** Uydurma riski büyük ölçüde engellenir, enterprise kullanımı için idealdir.

Kurumsal Dünyada RAG

Özellikle 2022-2024 yılları arasında büyük ivme kazanan RAG, kurumların LLM'leri gizli ve şirket içi verileriyle güvenli şekilde kullanabilmesi için endüstri standardı haline geldi.

- ✔ **Denetlenebilirlik (Auditability):** Sistem cevaplarının doğrudan orijinal şirket belgelerinden kontrol edilebilmesi operasyonel güven (trustworthiness) sağlar.
- 📈 **Maliyet Verimliliği:** Devasa dil modellerini sürekli yeniden eğitmek (fine-tuning) yerine, sadece veri tabanını (vektörleri) güncellemek çok daha hızlı ve ekonomiktir.



Image Sources



https://media.easy-peasy.ai/896d09bf-c199-418a-82a1-4305c241d1d/9024f422-Ofcc-4a98-a24d-99faa845dd58_medium.webp

Source: easy-peasy.ai



https://www.iqvia.com/-/media/iqvia/images/modules/brandworld/2000-2099/2095_strategy-office-team-meeting-analyzing-big-data-on-screen-with-executiv.png?mw=800&hash=2507A6D61F319E2ED56018C24C66AEC8

Source: www.iqvia.com